

Diseño, implementación, evaluación y análisis de un Sistem de Recuperación de Información

David Orlando De Quesada Oliva, Javier Domínguez

MATCOM, Universidad de La Habana.

`d.quesada@estudiantes.matcom.uh.cu`, `j.dominguez@estudiantes.matcom.uh.cu`

Abstract. Este artículo aborda sobre la implementación de un Sistema de Recuperación de Información usando el modelo vectorial y el modelo fuzzy para la recuperación de documentos de texto de diversos formatos.

Keywords: pdf, txt, idf, tf, peso, nltk, fuzzy, vectorial

Table of Contents

Diseño, implementación, evaluación y análisis de un Sistema de Recuperación de Información	1
<i>David Orlando De Quesada Oliva, Javier Domínguez</i>	
Diseño	3
Herramientas usadas para el desarrollo del sistema ..	4
Proceso para la creación de un sistema de recuperación de información	6
1 Preprocesamiento del texto:	6
2 Tokenización de los documentos del sistema y creación del vocabulario de las palabras:	10
3 Modelo vectorial:	11
3.1 Razones por la que se escogió este modelo como el modelo principal del sistema:	15
3.2 Limitaciones que tenemos al usar este modelo:	15
4 Modelo Fuzzy:	15
5 Evaluación del Modelo Vectorial:	18
6 Interfaz gráfica y como puede buscar las consultas el usuario:	18
References	19

Diseño

El sistema está diseñado, primero que todo, para pre-procesar los documentos que están en este. Este pre-procesamiento consiste en:

- Remover los stopwords (preposiciones, conjunciones y artículos).
- Remover los signos de puntuación.
- Remover los números.
- Llevar todas las palabras a minúscula.
- Stemming (llevar cada palabra a su palabra raíz).
- Separar por palabras el documento (tokenizar).

Los primeros 4 procesos en la implementación son modificables, o sea, es posible decidir si aplicarlos o no.

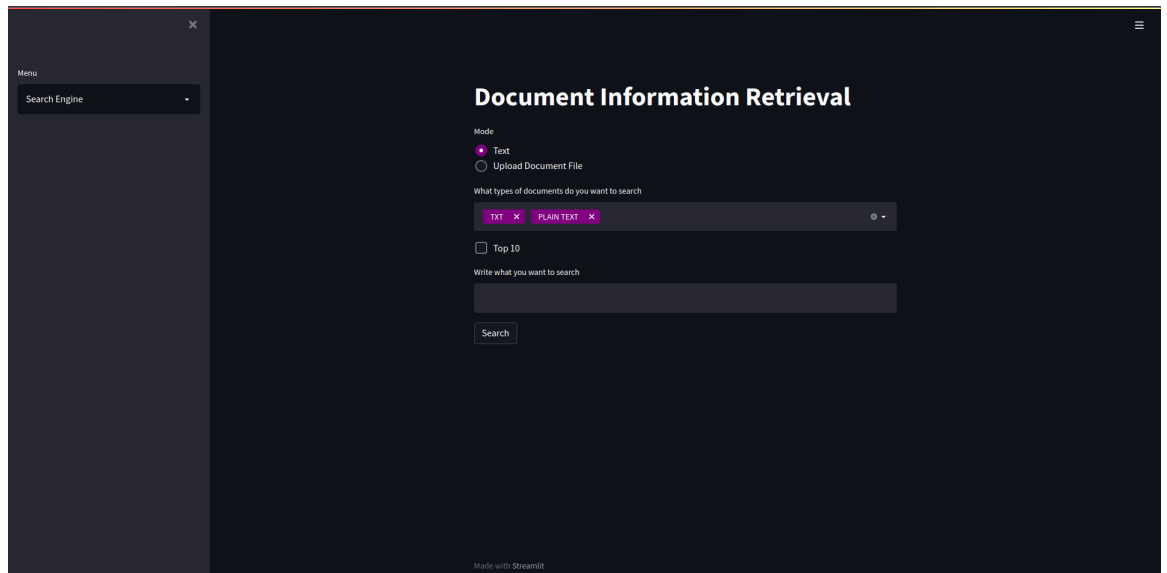
Herramientas usadas para el desarrollo del sistema

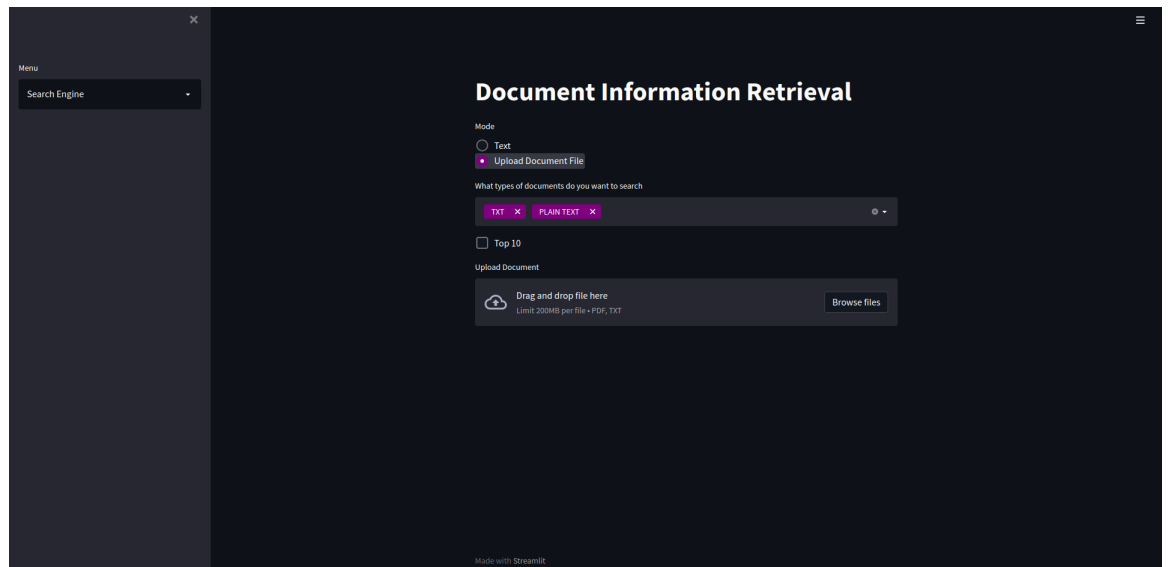
Para el desarrollo del sistema usamos Python como lenguaje de programación. Librerías de Python que utilizamos:

- nltk, para los stopwords, stemming y lemmatizing.
- streamlit para la interfaz gráfica.
- pdfminer y fpdf para procesar archivos .pdf.

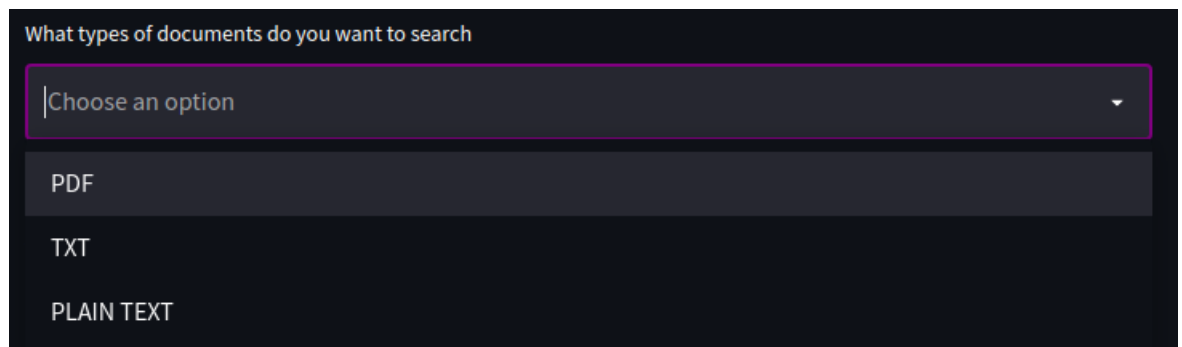
Para correr la aplicación: **streamlit run main.py**

Luego del pre-procesamiento es posible realizar las queries al sistema mediante la interfaz gráfica de dos formas, mediante texto, o mediante otro documento como se muestra en las imágenes siguientes:





Es posible escoger que formato de documento es el que se desea buscar:



Es posible escoger solamente los 10 elementos más relevantes de la query:



Proceso para la creación de un sistema de recuperación de información

1 Preprocesamiento del texto:

Siempre que tengamos datos textuales, debemos aplicar varios pasos de preprocesamiento a los datos para transformar palabras en tokens que permitan un mejor resultado del modelo. En el sistema de recuperación de información que se implementó es posible aplicar los siguientes pasos de preprocesamiento del texto. La implementación de los mismo está en el file **text processing.py**. En muchos pasos hacemos uso de la librería NLTK (Natural Language Toolkit) de Python.

Llevar el texto a minúsculas: Se lleva todo el texto a minúsculas para reducir el tamaño del vocabulario de nuestro texto.

Implementación hecha en Python:

```
def text_to_lowercase(text: str):  
    return text.lower()
```

Remover números:

Podemos remover los números o convertir los números en sus representaciones textuales.

Implementación hecha en Python haciendo uso de expresiones regulares para eliminar los números:

```
import re  
def remove_numbers(text):  
    return re.sub(r'\d+', '', text)
```

Implementación hecha en Python para convertir los números a sus expresiones textuales haciendo uso de la librería inflect:

```
import inflect  
def convert_numbers_into_words(text: str)-> str:  
    result = []  
    for word in text.split():  
        if word.isdigit():  
            result.append((inflect_engine.number_to_words  
                           (word)))  
        else:  
            result.append(word)  
    return ' '.join(result)
```

Remover los signos de puntuación:

Eliminamos los signos de puntuación para no tener diferentes formas de la misma palabra. Si no eliminamos los signos de puntuación, entonces por ejemplo **call**. **call!** ,**call** serán tratados por separado cuando deberían referirse a la misma palabra.

Implementación hecha en Python para remover los signos de puntuación:

```
def remove_punctuation_marks(text: str):
    translator = str.maketrans('', '', string.punctuation)
    return text.translate(translator)
```

Remover los stopwords:

Los stopwords son palabras que no contribuyen al significado de una oración. Por tanto pueden eliminarse con seguridad sin causar algún cambio en el significado de la oración. La biblioteca NLTK tiene un conjunto de stopwords y podemos usarlas para eliminar los stopwords de nuestro texto y devolver una lista de tokens de palabras.

LIST OF ENGLISH STOPWORDS IN NLTK:

their, few, wasn't, has, m, or, did, isn, very, themselves, you've, you'd, do, between, other, t, shan, yourself, does, ours, i, it, should, what, himself, so me, itself, there, weren, most, her, mustn, hers, doesn, won, doesn't, hasn, s, y, wouldn't, didn't, him, couldn, after, a, will, ain, than, for, being, which, during, ll, my, isn't, its, any, hadn't, his, then, don, of, shouldn't, out, ou r, have, such, o, nor, too, re, should've, needn't, same, she's, but, weren't, all, against, down, don't, can, you, under, where, wouldn, only, been, aren't, haven, that, doing, if, up, d, needn, ma, yours, shan't, wasn, because, about, those, he, are, was, at, hasn't, over, until, had, with, you're, below, have n't, mightn, here, own, off, both, whom, while, as, ourselves, they, further, m ightn't, these, from, to, them, she, who, were, more, am, why, your, aren, had n, in, won't, yourselves, no, me, didn, an, so, before, is, on, now, each, how, be, theirs, shouldn, mustn't, above, herself, just, you'll, the, through, agai n, once, having, by, when, myself, we, it's, this, that'll, couldn't, ve, and, into, not,

Fig. 1. Lista de stopwords de NLTK

Implementación hecha en Python para el proceso de eliminar los stopwords

```
from nltk.corpus import stopwords
def text_remove_stopword(text: str):
    stop_words = set(stopwords.words("english"))
    return ' '.join([word for word in text_tokenize(text)
                     if word not in
                     stop_words])
```

Stemming:

El stemming es el proceso mediante el cual se obtiene la raíz gramatical de una palabra. Stem es la parte a la que se le añaden los afijos flexivos (-ed, -ize, -de, -s, etc. En el caso del idioma inglés) El stem de una palabra es creado removiendo el prefijo o sufijo de la palabra. Por lo que el proceso de stemming de una palabra puede no resultar en palabras gramaticalmente correctas del idioma

	words	stemmed words			
0	friend	friend	books	--->	book
1	friends	friend	looked	--->	look
2	friended	friend	denied	--->	deni
3	friendly	friendli	flies	--->	fli

Fig. 2. Ejemplos del proceso de stemming en algunas palabras

Hay principalmente 3 algoritmos para hacer stemming **Porter Stemming**, **Snowball Stemmer** y el **Lancaster Stemmer**. El Porter Stemming es el más usado entre ellos.

Implementación hecha en Python para hacer el proceso de stemming. Se puede pasar como parámetro un string que indica con cual de los tres algoritmos se quiere hacer stemming.

```
from nltk.stem.porter import PorterStemmer
from nltk.stem.snowball import SnowballStemmer
from nltk.stem.lancaster import LancasterStemmer

porter_stemmer = PorterStemmer()
snowball_stemmer = SnowballStemmer(language='english')
lancaster_stemmer = LancasterStemmer()
```

```
def text_stem_words(text: str, stemmer: str):
    if text == 'porter':
        stemmer = porter_stemmer
    elif text == 'snowball':
        stemmer = snowball_stemmer
    else:
        stemmer = lancaster_stemmer

    stems = [stemmer.stem(word) for word in text_tokenize(text)]

    return ' '.join(stems)
```

Lemmatizing:

Como el stemming, el proceso de lemmatizing también convierte una palabra a su raíz gramatical. La única diferencia es que el lemmatizing asegura que la raíz gramatical de la palabra pertenezca al lenguaje. Obtenemos palabras válidas si usamos el lemmatizing. En **NLTK**, podemos hacer uso del **WordNetLemmatizer** para obtener los lemmas de las palabras.

Implementación en Python para el proceso de lemmatizing usando el WordNet de NLTK

```
from nltk.stem import WordNetLemmatizer
lemmatizer = WordNetLemmatizer()
def text_lemmatize_words(text: str):
    lemmas = [lemmatizer.lemmatize(word, pos='v') for word in text_tokenize(text)]
```



```
return ' '.join(lemmas)
```

Separar el texto en tokens:

El último paso que hacemos siempre (este paso es necesario) es separar el texto en una lista de tokens de palabras removiendo los espacios. Para eso hacemos uso del word tokenize de NLTK.

Implementación en Python para separar el texto en tokens

```
from nltk.tokenize import word_tokenize
def text_tokenize(text: str):
    tokens = word_tokenize(text)
    return tokens
```

De la forma en que está hecho el código se le puede pasar uno o varios pasos de preprocesamiento al texto según se requiera.

```
def text_preprocessing(*, text: str,
    lowercase: bool = False,
    remove_numbers: bool = False,
    convert_numbers: bool = False,
    remove_punctuation: bool = False,
    stopwords: bool = False,
    stem: str = None,
    lemmatize: bool = False):
    ...
```

El método recibe un texto y se le pasan en True los parámetros con los que se quiere filtrar el mismo. En el caso del parámetro stem se le pasa un string que indica con cual de los algoritmos se va a hacer el stemming.

Configuración predeterminada empleada:

```
def filter_and_tokenize_text(text: str):
    tokens = text_preprocessing(
        text=text,
        lowercase = True,
        convert_numbers= True,
        remove_punctuation=True,
        stopwords=True,
        lemmatize=True

    )

    return tokens
```

Este preprocesado de texto se le hace tanto a los documentos en el sistema como a cada query que se procese del usuario.

2 Tokenización de los documentos del sistema y creación del vocabulario de las palabras:

Por defecto todos los documentos que tiene el sistema están en el path:

```
'.\system_docs'
```

Para el preprocesado de los documentos del sistema se va por cada file del path y se lee el texto del documento (la forma de leer varía según el formato del mismo, consideramos aceptar .txt, pdfs y textos planos sin extensión) creamos una instancia de Doc con el nombre del documento, el path donde está realmente (útil para cuando el usuario haga la búsqueda pueda descargar el documento original), el tipo (TXT, PDF, o Texto Plano son los que consideramos), y el texto que al inicializarse se procesa el texto como se explicó previamente y nos quedamos con una lista de tokens que representan las palabras que tienen significación en ese el texto.

```
class Doc:

    def __init__(self, name: str, path: str, type: str, text=
        str):

        self.name = name
        self.path = path
        self.type = type
        self.terms = filter_and_tokenize_text(text)

    ...
```

Si en el path hay un folder se va recursivo por cada folder y se aplica lo mismo. De esta forma se va construyendo una lista de Doc que representan la información necesaria de los documentos que hay en el sistema. Al mismo tiempo se construye una lista con todos los términos distintos que aparecen en todos los documentos. Hacer estas operaciones son bastante costosas cuando se tienen bastante documentos en el sistema por lo que se hace solo cuando sea necesario porque se cambió o añadió nuevos documentos. Por lo que una vez obtenido las dos listas se serializa y guarda con **pickle** en los files documentos.pickle y **terms.pickle**. De esta forma no hay que estar generando cada vez sino que se lee el archivo.

El código de implementación de este proceso está en

```
system_docs_preprocessing.py
```

Para decir que se quiere hacer el preprocesado de los documentos del sistema y generar nuevos files se llama al handler con el parámetro system docs preprocess required en True

```
handler = Retrieval_handler(system_docs_preprocess_required=
    True,
    model_preprocess_required=True, retrieval_model_used='
        vectorial')

    ...
```

En caso que sea False el handler internamente cargará los files pickle correspondientes.

3 Modelo vectorial:

El modelo principal que usamos para el sistema de recuperación de información fue el vectorial. Este modelo representa los documentos como vectores en un espacio vectorial común, donde cada dimensión corresponde a un término independiente.

Por ejemplo:

Sea d_j el documento j y i, \dots, t el t -ésimo término entonces el vector del documento j quedaría:

$$d_j = (w_{1,j}, w_{2,j}, \dots, w_{t,j})$$

Si aparece un término en el documento, su valor en el vector es distinto de 0. El esquema usado para calcular estos valores se conoce como **tf-idf weighting**. El peso(weight) asociado al par (t_i, d_j) es ≥ 0 .

Calculo del peso en los documentos:

El peso del término t_i en el documento d_j está dado por:

$$w_{i,j} = tf_{i,j} * idf_i$$

El idf(inverse document frequency) de un término i se define:

$$idf_i = \log \frac{N}{n_i}$$

Donde N es la cantidad de documentos existentes en el sistem y n_i la cantidad de documentos en los que aparece el término t_i .

La frecuencia normalizada del término t_i en el documento d_j se define como:

$$t_{i,j} = \frac{freq_{i,j}}{\max_l freq_{l,j}}$$

Donde $freq_{i,j}$ es la frecuencia del término t_i en el documento d_j y $max_l freq_{l,j}$ la máxima frecuencia que tiene un término l en el documento j .

Para representar este modelo creamos una clase `Vectorial`

[illegible]

```

self.documents = documents # documents of the corpus of
                           the form Doc()
if compute_vectorial_data_required:
    self.compute_docs_vectors()
else:
    self.d_vectors = unpick_pickle_file('./preprocessed/
                                         d_vectors.pickle')
    self.idf = unpick_pickle_file('./preprocessed/idf.
                                   pickle')
...

```

la cual se inicializa con el vocabulario y la lista que tiene la representación de cada documento del corpus así como con un parámetro opcional que indica que es necesario calcular el vector de cada documento o se lee directo de un file .pickle serializado, esto es debido a que hacer este proceso es extremadamente costoso por lo que se hace previamente y solo es necesario volverlo a cambiar si cambia el corpus (se agregan o modifican nuevos documentos).

Con el método:

```

def compute_docs_vectors(self):
...

```

se calculan el vector de cada documento con el esquema idf-tf para calcular los pesos de cada documento con cada término del vocabulario del corpus.

```

N = len(self.documents)
len_terms = len(self.corpus_terms)
d_vectors = [ len_terms*[0] for _ in range(N) ]
tf = [N*[0] for _ in range(len_terms)]
idf = len_terms*[0]
for doc_id, doc in enumerate(self.documents):

    if doc.terms:
        freq_counter = Counter(doc.terms)
        max_freq_dj = freq_counter.most_common(1)[0][1]
        for term_id, term in enumerate(self.corpus_terms):
            freq_ij = freq_counter[term]
            tf[term_id][doc_id] = freq_ij/max_freq_dj
...

```

Primero se computa el tf para cada término del corpus con cada documento y se guarda en una lista tf tal que $tf[t_i][d_j]$ me de el tf del término con posición t_i en la lista de términos y del documento con posición d_j en la lista de documentos.

```

terms_appear = len_terms*[0]
for term_id, term in enumerate(self.corpus_terms):
    for doc in self.documents:
        if term in doc.terms:

```

```

...
terms_appear[term_id] += 1

```

Luego calculamos para cada término la cantidad de documentos en los que este aparece y lo guardamos en la lista *terms_appear*

```

for term_id, term in enumerate(self.corpus_terms):
    idf[term_id] = math.log(N/terms_appear[term_id])
...

```

Luego se calcula el idf para cada término usando la lista previamente calculada *terms_appear* para obtener el n_i de cada término y guardamos el resultado en la lista idf.

```

for dj in range(N):
    for term_id, _ in enumerate(self.corpus_terms):
        d_vectors[dj][term_id] = tf[term_id][dj] *
                                idf[term_id]
...

```

Luego vamos por cada documento d_j y cada término t_i y se calcula el peso $w_{i,j}$ usando las listas de tf e idf previamente calculadas y finalmente nos queda un vector de cantidad de términos en el vocabulario componentes por cada documento del corpus.

Finalmente se serializan la lista de vectores y el idf(necesario para calcular el peso de las query) usando pickle y se guarda en los files *d_vectors.pickle* y *idf.pickle*

Querys en el modelo vectorial:

Las querys también se representan como un vector q

$$q = (w_{1,q}, w_{2,q}, \dots, w_{n,q})$$

El cálculo del peso es bastante similar a como es con los documentos con la diferencia que se introduce una constante de suavizado a.

$$w_{i,q} = (a + (1 - a) * \frac{freq_{i,q}}{maxfreq_{i,q}})$$

```

def compute_query_vector(self, query: str):
...

```

con este método se computa el vector de una query.

Luego de hacer primero el preprocesado del texto y tener los tokens calculamos el peso como se ve a continuación:

```

q_vector = len(self.corpus_terms)*[0]

```

```

if tokens:
    freq_counter = Counter(tokens)
    max_freq_q = freq_counter.most_common(1)[0][1]
    for ti, term in enumerate(self.corpus_terms):
        freqiq = freq_counter[term]
        tf_ti_q = self.a + (1 - self.a) * (freqiq /
                                           max_freq_q)

        idf_ti = self.idf[ti]
        w_iq = tf_ti_q * idf_ti
        q_vector[ti] = w_iq
return q_vector
...

```

La query puede ser vacía (no tener ningún término) en dicho caso el vector sería 0 en cada una de sus componentes. **Cálculo de la similitud:**

El cálculo de similitud entre un documento y la query se hace comparando la desviación de ángulos entre el vector del documento y el vector de la query (la cual tiene dimensión igual a los vectores que representan los otros documentos).




Fig. 3.
Visualización
con vectores de 2
dimensiones

Para calcular la similitud hacemos $sim_{d_j,q} = \cos\theta = \frac{d_j * q}{||d_j|| ||q||} = \frac{\sum_{n=1}^N w_{i,j} w_{i,q}}{\sqrt{\sum_{n=1}^N w_{i,j}^2} \sqrt{\sum_{n=1}^N w_{i,q}^2}}$

Con esto se tiene una ordenación por relevancia (los que tengan mayor similitud) de los documentos respecto a la query.

Implementación realizada en Python para el cálculo de la similitud

```

def sim(self, v1: List[float], v2: List[float]) -> float:
    dotproduct = 0
    for i in range(len(v1)):
        dotproduct += v1[i]*v2[i]

    norm1 = 0
    for i in v1:
        norm1 += i*i
    norm1 = math.sqrt(norm1)

```

```

norm2 = 0
for i in v2:
    norm2 += i*i
norm2 = math.sqrt(norm2)

return dotproduct/(norm1*norm2)
....

```

Se puede establecer un umbral de similitud y quedarnos solamente con los documentos que son mayores que ese umbral.

3.1 Razones por la que se escogió este modelo como el modelo principal del sistema:

- Este modelo es bastante sencillo de implementar y ofrece notables mejoras respecto al booleano.
- La estrategia de coincidencia parcial permite la recuperación de documentos que se aproximen a los requerimientos de la consulta.
- El esquema de ponderación tf-idf para los documentos mejora el rendimiento de la recuperación.
- La fórmula del coseno ordena los documentos de acuerdo al grado de similitud con la consulta.

3.2 Limitaciones que tenemos al usar este modelo:

- Uno de los problemas que tiene es la sensibilidad semántica; los documentos con un contexto similar pero con un vocabulario de términos diferente no se asociarán, lo que resultará en una coincidencia negativa falsa.
- Teóricamente asume que los términos son estáticamente independientes
- El orden en que los términos aparecen en el documento se pierde en la representación en el espacio vectorial

4 Modelo Fuzzy:

Se implementó como modelo secundario para tener la opción de elegir si se quería probar con el mismo.

El modelo fuzzy es una extensión del modelo booleano. En este modelo cada término de la query es definido mediante un conjunto difuso y cada documento tiene un grado de pertenencia a dicho conjunto (valor entre 0 y 1). La idea básica es expandir el conjunto de términos de índice en la consulta con términos relacionados, de modo que la consulta del usuario pueda recuperar documentos relevantes adicionales. Se puede usar un thesaurus para modelar el problema de recuperación de información en términos de conjuntos difusos. Un thesaurus puede ser construido definiendo una matriz de correlación término a término

cuyas filas y columnas están asociada a los términos de la colección de documentos. En dicha matriz, un factor de correlación normalizado $c_{i,l}$ entre dos términos k_i y k_l se define de la siguiente forma:

$$c_{i,l} = \frac{n_{i,l}}{n_i + n_l - n_{i,l}}$$

Donde n_i es el número de documentos que contienen al término k_i , n_l el número de documentos que contienen al término k_l , $n_{i,l}$ el número de documentos que contienen a ambos términos

Podemos usar la matriz de correlación para definir un conjunto difuso asociado a cada término k_i . En este conjunto difuso, un documento d_j tiene un grado de pertenencia (grade of membership) $\mu_{i,j}$ que se define como:

$$\mu_{i,j} = 1 - \prod_{k_l \in d_j} (1 - c_{i,l})$$

Un documento d_j pertenece al conjunto difuso asociado al término k_i si sus términos están relacionados con k_i . Siempre que haya un término k_l de d_j que esté fuertemente relacionado ($c_{i,l} \sim 1$), entonces $\mu_{i,j} \sim 1$ y el término k_i es un buen fuzzy index para el documento d_j . En el caso que todos los documentos de d_j estén pobremente relacionados con k_i , k_i no es un buen fuzzy index para d_j ($\mu_{i,j} \sim 0$).

La similitud entre un documento d_j y la query q se define:

$$sim(q, d_j) = 1 - \prod_{i=1}^N (1 - \mu_{k_i, d_j})$$

Donde N es la cantidad de términos de la query.

Entonces te puedes quedar con los documentos ordenados por ranking de relevancia respecto a la query.

Para la implementación de este modelo se definió una clase Fuzzy

```
class Fuzzy:
def __init__(self, corpus_term, documents,
              compute_fuzzy_data_required:
                  bool = False):
    self.corpus_terms: List['str'] = corpus_term
    self.documents: List['Doc'] = documents
    self.correlation_matrix = {}
    if compute_fuzzy_data_required:
        self.compute_fuzzy_data()
    else:
        self.deg_memb_matrix = unpick_pickle_file('./
                                                preprocessed/
                                                deg_memb_matrix.pickle
                                                ')
    ...
```

Recibe los términos del vocabulario y los documentos así como el parámetro *compute_fuzzy_data_required* que indic si es necesario hacer el preprocesado de

calcular la matriz de grado pertenencia o se puede cargar desde un file previamente salvado **.pickle**

Implementación hecha en Python para el cálculo de la matriz de correlación:

```
def correlation_factor(self, ki: str, kl: str):
    if (ki,kl) in self.correlation_matrix:
        return self.correlation_matrix[(ki, kl)]
    if (kl, ki) in self.correlation_matrix:
        return self.correlation_matrix[(kl, ki)]
    n_i = 0
    n_l = 0
    n_i_l = 0
    for doc in self.documents:
        if ki in doc.terms:
            n_i+=1
        if kl in doc.terms:
            n_l+=1
        if ki in doc.terms and kl in doc.terms:
            n_i_l +=1
    result = n_i_l/(n_i + n_l - n_i_l) # ci,l
    self.correlation_matrix[(ki, kl)] = result
    return result
...
```

Implementación hecha en Python para el cálculo del grado de pertenencia de un documento dj al conjunto difuso de un término ki:

```
def degree_of_membership(self, ki, dj):
    if (ki, dj) in self.deg_memb_matrix:
        return self.deg_memb_matrix[(ki, dj)]
    result = 1
    for term in self.documents[dj].terms:
        result *= 1- self.correlation_factor(ki, term)
    result = 1 - result
    return result
...
```

Implementación hecha en Python para el cálculo de la similitud entre la query y un documento:

```
def sim(self, q, dj):
    result = 1
    for t in q:
        result *= 1 - self.deg_memb_matrix[(t, dj)]
```

```
        result = 1- result
    return result
...
```

Para obtener los documentos más relevantes se va por cada documento se calcula la similitud de cada uno con la query como se explicó anteriormente y al final se hace un ranking por relevancia bastante similar a como es con el vectorial. También se puede considerar un umbral de similitud y quedarte solamente con los resultados por encima de dicho umbral.

5 Evaluación del Modelo Vectorial:

6 Interfaz gráfica y como puede buscar las consultas el usuario:

La interfaz gráfica se desarrolló con **streamlit** una biblioteca bastante cómoda para crear aplicaciones de interfaz web desde Python. En el file *UI_streamlit.py* está el código de la parte gráfico del sistema de recuperación de información desarrollado.

References

1. Ritika Hirwane(2012). Fundamental of Content Based ImageRetrieval. (IJCSIT) International Journal of Computer Science and Information Technologies, Vol. 3 (1)
2. Hui Hui Wang, Dzulkifli Mohamad, N.A. Ismail(2010). Approaches, Challenges and Future Direction of Image Retrieval. Journal of Computing, Volume 2, Issue 6
3. Chandra Mouli P.V.S.S.R.,Mohd Khalid Vijayan Vijayarajan(2012). A review: from keyword based image retrieval to ontology based image retrieval.International Journal of Reviews in Computing
4. John Eakins,Margaret Graham(1999). Content-based Image Retrieval. JISC Technology Applications Programme (October 1999)
5. Yu Xiaohong, Xu Jinhua(2008) The Related Techniques of Content-based Image Retrieval. 2008 International Symposium on Computer Science and Computational Technology
6. Elsaheed E. Abdelrazek(2017). A Comparative Study of Image Retrieval Algorithms for Enhancing a Content-based Image Retrieval System. Global Journals of Computer Science and Technology:Inc Volume 17 Issue 3 Version 1.0
7. Abby A. Goodrum(2000). Image Information Retrieval: An Overview of Current Research. College of Information Science and Technology Drexel University.
8. Unknown Author(2021,November 26). Image retrieval.Wikipedia.https://en.wikipedia.org/wiki/Image_retrieval.